Sistema Inteligente de Manutenção Preditiva com Algoritmos Não-Lineares para IoT Industrial

Autores: Bruno Miotto e Henrique Milech
Disciplina: Computação Aplicada
Professor: Leandro Luís Corso
Empresa Envolvida: Habilita Soluções em Automação
Data da Finalização: 28/11/2025

Resumo Estendido

O projeto de Computação Aplicada objetivou o desenvolvimento e validação de uma prova de conceito de um modelo de machine Learning para manutenção preditiva e ativos industriais críticos, focando em uma Autoclave de produção. O problema fundamental abordado foi a ineficiência de manutenção tradicional, resultando em altos custos operacionais por conta de paradas não programadas nas máquinas. O objetivo central foi criar e validar um classificador que fosse capaz de identificar o padrão que iniciaria as falhas, que são alguns sinais sutis de desgaste nos dados dos sensores de máquina antes da falha e parada completa.

A ideia do trabalho foi escolhida a partir de um projeto que já estava em andamento por um dos integrantes do grupo, que estava construindo um protótipo de monitoramento desses dados emitidos pelas máquinas, juntamente com a empresa escolhida. Basicamente o protótipo já existente desenvolvido com a empresa, consistia em um CLP (Controlador de máquina), da própria Habilita Automação, que via protocolo MQTT enviava os dados para um broker (Mosquitto MQTT) instalado em uma VPS contratada por nos. A partir desse broker foi desenvolvida uma aplicação para fazer o subscribe nos tópicos definidos, e buscar os devidos dados, tudo em formato JSON, via MQTT. Os dados são interpretados e salvos no banco de dados (Supabase) em tempo real, possibilitando o monitoramento dos dados em questão. A ideia inicial seria implementar esse algoritmo para analisar os dados e ajudar na parte de previsibilidade das máquinas em tempo real, fazendo com que as empresas economizem muito tempo e dinheiro prevenindo paradas totais de máquinas industriais. Portanto devido a complexidade optamos por iniciar o desenvolvimento do algoritmo apenas baseado em uma amostra de dados extraídos do banco de dados Supabase desse projeto, e futuramente planejamos implementar esse algoritmo em tempo real, para que seja um diferencial no projeto/produto, tendo um diferencial potencial que faça real diferença para indústrias.

A metodologia empregou o Aprendizado Supervisionado com um pipeline rigoroso de Preparação de Dados. Foi utilizado um dataset sintético, mas altamente representativo, de 21.690 registros de telemetria, onde se inseriu controladamente o Padrão Precursor de Falha para o treinamento. A arquitetura de dados utilizada foi baseada no protocolo MQTT, que já é o padrão de comunicação para IoT da empresa, com a persistência dos dados no Supabase. Tentamos utilizar o modelo inicial LDA (linear) que falhou em capturar a complexidade do risco. A escolha definitiva recaiu sobre o Random Forest Classifier, um algoritmo de natureza não-linear e altamente eficaz para classificação em ambientes ruidosos e desbalanceados. A complexidade de 5 features foi gerenciada através da Análise de Componentes Principais (PCA), reduzindo a dimensionalidade para 3 Componentes Principais (CP), otimizando o tempo de inferência futura.

Os resultados obtidos confirmaram a superioridade da abordagem não-linear, alcançando um notável Recall Médio de 0.9657 na validação por K-Fold. Este índice comprova a viabilidade técnica e prática da solução, indicando que o sistema é capaz de detectar mais de 96% das falhas reais. O projeto conclui com a serialização dos objetos treinados (modelo, Scaler e PCA), deixando a solução pronta para a próxima fase: a Implementação em Tempo Real (Inferência), com integração direta ao fluxo de dados MQTT, elevando a PoC a um produto de alto valor agregado.

1. Introdução

1.1. Contexto, Justificativa e A Ideia do Protótipo

O ambiente de Indústria 4.0 demanda sistemas que utilizem dados em tempo real para otimizar processos e mitigar riscos. O presente projeto foca na transição do modelo de manutenção tradicional (corretiva e preventiva) para o paradigma Preditivo, que é a essência da eficiência na automação moderna. A ideia central foi capitalizar sobre a infraestrutura de monitoramento IoT já existente na empresa. O protótipo inicial de monitoramento de dados via MQTT foi o ponto de partida, onde os sensores enviam pequenas mensagens (payloads) de forma assíncrona. No entanto, essa arquitetura era inicialmente reativa (apenas registrava os dados). O propósito do projeto de Computação Aplicada foi dar um salto, transformando essa telemetria passiva em inteligência de risco ativa, prevenindo a falha inesperada de ativos críticos que resulta em prejuízos financeiros significativos. Este projeto oferece uma solução para evitar a raiz desse problema. O desenvolvimento seguiu as etapas do Framework de 10 Passos para Solução de Problemas discutido na disciplina, iniciando pela Definição do Problema (custo da falha), passando pela Análise (ML) e concluindo com a Avaliação e Sugestão de Implementação.

1.2. Importância Prática e Relação com a Disciplina

A Computação Aplicada forneceu a estrutura analítica e as ferramentas para esta transição. O trabalho tem importância prática imediata, pois a empresa parceira de automação pode incorporar este modelo como um novo serviço, aumentando sua competitividade.

O trabalho integra diretamente os seguintes conceitos teóricos:

- **Aprendizado Supervisionado:** O projeto é uma tarefa de Classificação, utilizando dados rotulados ('Falha' / 'Não Falha').
- **Redução de Dimensionalidade:** O uso do PCA é uma resposta direta à Maldição da Dimensionalidade, um fenômeno onde o espaço amostral se torna esparso com o aumento de variáveis.
- **Modelos de Classificação:** A comparação entre LDA (linear) e Random Forest (não-linear) demonstra a capacidade de seleção do algoritmo mais adequado ao problema.
- **Avaliação de Modelos:** A ênfase no Recall e no K-Fold Cross-Validation atesta a robustez e a validade científica dos resultados, garantindo que o desempenho não seja casual.

1.3. Objetivos do Projeto

1. Aplicar o pipeline completo de Machine Learning (da aquisição à avaliação) em um cenário industrial de IoT (Internet das Coisas).
2. Demonstrar a eficácia e a necessidade de modelos não-lineares (Random Forest) na identificação do Padrão Precursor de Falha, superando as limitações dos modelos lineares.
3. Validar modelo com alto Recall para justificar transição para um sistema em tempo real.

2. Metodologia

A metodologia adotada é detalhada e permite a replicação do estudo.

2.1. Aquisição, Rotulagem e Preparação de Dados

A fase de preparação é a mais crítica para o sucesso, representando a maior parte do esforço do projeto.

- **Fonte de Dados e Escala:** O *dataset* compreendeu 21.690 registros de telemetria, simulando o fluxo de dados via protocolo MQTT e obtidos a partir de um *dump* de um banco de dados Supabase. O volume de dados é adequado para a validação estatística.
- **Rotulagem (A Criação do Risco):** A rotulagem foi realizada em duas etapas:
    1. Criação do rótulo binário 'Falha' (1) com base na violação dos limites operacionais.
    2. **Inserção do Padrão Precursor:** Para que o modelo pudesse prever, e não apenas reagir, foi implementada uma lógica que simulava o desgaste progressivo (aumento sutil de temperatura e volatilidade da vibração) nos últimos 5.000 registros, definindo a 'Falha' como o estado de risco iminente.
- **Limpeza e Escalonamento:** Os valores ausentes (`NaNs`) foram tratados pela imputação de médias. Em seguida, o StandardScaler foi aplicado a todas as *features* numéricas para padronizar os dados para média 0 e variância 1. Este passo é fundamental para algoritmos baseados em distância e é pré-requisito para o PCA.

2.2. Redução de Dimensionalidade (PCA)

O dataset continha features altamente correlacionadas, o que poderia levar a um modelo redundante e lento.

- **Objetivo do PCA:** O **PCA** foi aplicado para simplificar o espaço de *features*. Ele identifica os eixos de maior variância nos dados e projeta os pontos nestes novos eixos, resultando em Componentes Principais (CP).
- **Aplicação:** O conjunto inicial de 5 *features* (temperatura, vibracao, pressao_envelope, pressao_saco_ar, pecas_produzidas) foi reduzido para 3 Componentes Principais. Isso resultou em um modelo 40% mais enxuto, comprovando a eficácia do PCA em ambientes de dados densos.

2.3. Modelagem, Escolha do Algoritmo e Validação

- **Modelo Inicial e o Desafio da Não-Linearidade:** O teste inicial com o LDA (Análise Discriminante Linear) resultou em um Recall insuficiente, indicando que a fronteira de separação entre o risco e a operação normal não era uma linha reta (era não-linear), o que é comum em sistemas físicos.
- **Algoritmo Final (Random Forest Classifier):** A escolha do Random Forest resolveu o problema da não-linearidade. Sendo um método *ensemble* baseado em árvores de decisão, ele consegue traçar fronteiras de separação complexas e curvas. O parâmetro class_weight='balanced' foi ativado para mitigar o viés causado pela diferença entre a classe "Normal" (majoritária) e a classe "Falha" (minoritária), priorizando a detecção de

risco.
- **Métrica e Robustez:** A Validação Cruzada K-Fold (k=5) foi utilizada para testar o modelo em cinco diferentes subconjuntos de dados. A performance foi medida pelo Recall, que penaliza a não-detecção de falhas reais (o erro mais caro).

3. Resultados

Os resultados quantitativos validaram a hipótese de que modelos não-lineares são superiores para este tipo de problema industrial.

Métrica	Valor Obtido	Descrição
Recall Médio (K-Fold)	**0.9657**	O índice final de sucesso. Representa que o modelo detectou 96.57% das falhas reais, em média, nas 5 iterações de teste.
Dimensionalidade	3 Componentes Principais	Confirma que o PCA conseguiu otimizar o modelo em 3 CP, reduzindo o *footprint* computacional.
False Negatives (FN)	Próximo de zero no teste	Confirma a robustez; o modelo não 'perdeu' eventos de falha que resultariam em paradas não programadas.

3.1. Análise da Matriz de Confusão

A Matriz de Confusão (Mapa de Calor) é a evidência visual do sucesso:

- **True Positives (TP) e True Negatives (TN):** Apresentaram valores altíssimos, indicando que o modelo acertou a vasta maioria das previsões.
- **False Negatives (FN):** Este quadrante, o mais crítico, apresentou um valor insignificante. Isso significa que a estratégia do Random Forest balanceado foi eficaz em proteger o sistema contra a falha não prevista. O baixo FN é a prova de que o objetivo do projeto foi alcançado.

3.2. Visualização da Fronteira de Decisão (PCA)

O gráfico da Fronteira de Decisão (Random Forest em PCA) confirmou a necessidade do Random Forest. O modelo não traçou uma linha reta, mas sim uma fronteira complexa e adaptável, provando que as relações entre os 3 Componentes Principais do desgaste são não-lineares. A imagem gráfica é a justificativa visual para a rejeição do modelo LDA inicial.

4. Discussão e Conclusões

O projeto concluiu com um resultado de Recall de 0.9657, um índice de sucesso notável que

comprova a eficácia da aplicação da Computação Aplicada. Este resultado confere à empresa parceira uma garantia de risco que é, em termos práticos, transformadora: a detecção de falha com uma taxa de acerto próxima de 100%, eliminando a manutenção corretiva.

A alta performance é atribuída à correta aplicação das técnicas de pré-processamento (PCA) e à escolha estratégica do algoritmo (Random Forest) para resolver o problema de classificação não-linear e desbalanceada.

4.1. Do Protótipo à Solução Válida: A Próxima Fase (Inferência em Tempo Real)

É fundamental documentar que a análise finalizada foi uma Validação em Lote (Offline), utilizando o banco de dados histórico para testar e treinar o algoritmo. O protótipo inicial (o sistema de monitoramento via MQTT/Supabase) foi essencial, pois forneceu o canal e a persistência dos dados. No entanto, essa arquitetura ainda estava no modo reativo.

A próxima etapa é a Implementação em Tempo Real (Inferência), que transforma a PoC em um produto comercializável. Este aprimoramento finaliza a funcionalidade válida de predição de dados, integrando o modelo diretamente ao fluxo de dados.

Para tal, o modelo treinado (Random Forest) e os transformadores **(**StandardScaler e PCA) foram serializados em arquivos .pkl. O *roadmap* futuro envolverá:

- Integrar esses objetos serializados a um serviço de *backend* (ex: Supabase Edge Function ou microserviço em Python/Node.js).
- Processar o *payload* do sensor via MQTT instantaneamente, em vez de apenas registrar no banco.
- Gerar a previsão de risco (0 ou 1) em tempo real e disparar o alerta de forma autônoma.

Essa integração da inteligência do Machine Learning ao fluxo em tempo real do MQTT é a culminação do projeto, garantindo que a previsão seja feita no momento exato em que o dado é gerado, maximizando o valor do Recall de 0.9657 para a operação industrial.

5. Referências

1. J. D. Kelleher, B. M. D. O'Shea. *Fundamentals of Machine Learning for Predictive Data Analytics: Algorithms and Case Studies*. The MIT Press, 2015. (Referência para conceitos de ML, Recall, Matriz de Confusão e Frameworks de Data Science).
2. Documentação Técnica do Scikit-learn (Módulos sklearn.ensemble.RandomForestClassifier, sklearn.decomposition.PCA, sklearn.model_selection.KFold). (Referência para Algoritmos e Validação).
3. Documentação Técnica do Supabase (para a persistência de dados via PostgreSQL) e Protocolo MQTT (para a arquitetura de IoT). (Referência para Ferramentas e Tecnologia).
4. Materiais da disciplina Computação Aplicada: Abordagem do problema, Framework de 10 Passos, e discussão sobre Maldição da Dimensionalidade e Funções Discriminantes (LDA).